Validação Estatística do Alinhamento Semântico da *Smallest-Last Ordering* (SLO) para a Coloração Grundy

Explicação pedagógica do teste de permutação
e sua relação com a escolha de ordenação na formulação de representantes

2 de maio de 2026

Contexto: por que a ordenação importa

Na formulação de programação inteira por representantes assimétricos para a Coloração Grundy, o conjunto de variáveis de decisão é indexado por

$$\mathcal{X} = \big\{(u,v) \;\big|\; v \in \overline{N}(u),\ \sigma(u) \le \sigma(v)\big\},$$

onde $\sigma : V \to \{0,\dots,n-1\}$ é uma ordem total sobre os vértices. Para cada aresta $\{u,v\} \in \overline{E}$, exatamente um dos pares (u,v) ou (v,u) pertence a $\mathcal{X}$: aquele em que o primeiro elemento tem menor σ. O vértice de menor σ em cada classe de cor é, portanto, o *representante canônico* dessa classe no modelo.

A hipótese de alinhamento semântico afirma:

A SLO, ao atribuir índices menores a vértices de maior grau residual, posiciona como representantes canônicos exatamente os vértices que tendem a ser representantes nas soluções ótimas da Coloração Grundy.

Para testar essa hipótese de forma rigorosa, utilizamos um **teste de permutação**, descrito nas seções seguintes.

A estatística de teste: rank médio normalizado

Definição

Seja $G = (V,E)$ um grafo com n vértices e seja $\mathrm{OPT}(G)$ o conjunto de todas as colorações Grundy ótimas de G, isto é, aquelas que utilizam $\Gamma(G)$ cores. Para uma ordem σ e uma coloração $C \in \mathrm{OPT}(G)$ com classes $V_1^C,\dots,V_\Gamma^C$, define-se o *representante canônico* da classe i como

$$r_i^C(\sigma) \;=\; \arg\min_{v \in V_i^C} \sigma(v).$$

Definição: Rank médio normalizado $\bar{r}(\sigma)$

O *rank médio normalizado* da ordem σ é

$$\bar{r}(\sigma) \;=\; \frac{1}{|\mathrm{OPT}(G)|\cdot\Gamma(G)} \sum_{C\in\mathrm{OPT}(G)} \sum_{i=1}^{\Gamma(G)} \sigma\big(r_i^C(\sigma)\big) \;-\; \frac{\Gamma(G)-1}{2},$$

onde o termo $(\Gamma(G)-1)/2$ é a normalização pelo melhor caso possível: se os $\Gamma(G)$ representantes ocupassem as posições $0,1,\dots,\Gamma(G)-1$, o rank médio bruto seria exatamente $(\Gamma(G)-1)/2$.

Intuição

$\bar{r}(\sigma) = 0$ significa que, em média sobre todas as soluções ótimas, os representantes canônicos ocupam as Γ primeiras posições da ordem σ — o melhor cenário possível. $\bar{r}(\sigma) > 0$ significa que os representantes estão, em média, deslocados para posições mais tardias. Valores menores de $\bar{r}(\sigma)$ indicam melhor alinhamento semântico da ordem σ com a estrutura das soluções ótimas.

Por que não basta comparar com uma única ordem aleatória

Uma abordagem ingênua compararia $\bar{r}(\sigma_{\text{SLO}})$ com $\bar{r}(\sigma_{\text{rnd}})$ para uma única permutação aleatória σ_{rnd}. Essa abordagem é estatisticamente inadequada por duas razões:

1. **Alta variância:** uma permutação aleatória pode por acaso ser melhor ou pior que a SLO sem que isso reflita o comportamento médio do acaso.
2. **Sem significância:** não é possível afirmar que a diferença observada é sistemática ou fruto do acaso com apenas um ponto de comparação.

O correto é comparar $\bar{r}(\sigma_{\text{SLO}})$ com a **distribuição** de $\bar{r}(\sigma)$ quando σ é amostrada uniformemente ao acaso.

O teste de permutação

Estrutura do teste

O teste de permutação é um método **não paramétrico**: não assume nenhuma distribuição paramétrica para a estatística de teste. Sua única hipótese é que, sob a hipótese nula, todas as permutações de V são igualmente prováveis — o que é exatamente verdade quando σ é amostrada uniformemente.

O teste é estruturado em cinco passos:

Passo 1. Enumeração das soluções ótimas. Calcula-se $\Gamma(G)$ e enumera-se $\text{OPT}(G)$ por força bruta (viável para $n \leq 9$, pois há $n!$ permutações a testar).

Passo 2. Cálculo do valor observado. Computa-se $\bar{r}(\sigma_{\text{SLO}})$, a estatística de teste para a SLO. Este é o valor que queremos avaliar.

Passo 3. Construção da distribuição de referência. Geram-se N permutações aleatórias $\sigma_1, \ldots, \sigma_N$ e calcula-se $\bar{r}(\sigma_k)$ para cada uma, obtendo a amostra

$$\mathcal{R} = \{\bar{r}(\sigma_1), \ldots, \bar{r}(\sigma_N)\}.$$

A média e o desvio padrão dessa amostra estimam o comportamento médio do acaso:

$$\mu_{\text{rnd}} = \frac{1}{N}\sum_{k=1}^{N} \bar{r}(\sigma_k), \qquad \sigma_{\text{rnd}} = \sqrt{\frac{1}{N-1}\sum_{k=1}^{N}\big(\bar{r}(\sigma_k) - \mu_{\text{rnd}}\big)^2}.$$

Passo 4. Cálculo do p-valor empírico. O p-valor unilateral à esquerda é a fração de ordens aleatórias que obtiveram resultado *tão bom ou melhor* que a SLO:

$$\hat{p} \;=\; \frac{\#\{k \in \{1, \ldots, N\} : \bar{r}(\sigma_k) \leq \bar{r}(\sigma_{\text{SLO}})\}}{N}. \tag{1}$$

Um p-valor pequeno indica que poucas ordens aleatórias conseguem igualar ou superar a SLO — evidência de alinhamento semântico.

Passo 5. Decisão estatística. Adota-se o critério convencional:

$$\hat{p} < 0{,}05 \implies \text{rejeita-se } H_0 \quad \text{(resultado significativo)},$$

onde H_0 é a hipótese nula de que a SLO não é melhor que o acaso.

Hipóteses do teste

$$\begin{aligned} H_0 &: \bar{r}(\sigma_{\text{SLO}}) \geq \mathbb{E}_\sigma[\bar{r}(\sigma)] \quad \text{(SLO não é melhor que o acaso)} \\ H_1 &: \bar{r}(\sigma_{\text{SLO}}) < \mathbb{E}_\sigma[\bar{r}(\sigma)] \quad \text{(SLO posiciona representantes mais cedo)} \end{aligned}$$

O teste é **unilateral à esquerda**: interessa apenas saber se a SLO é *melhor* que o acaso, não se é diferente em qualquer direção.

Precisão do p-valor empírico

O p-valor empírico $\hat{p}$ é uma proporção amostral. Seu erro padrão é

$$\text{EP}(\hat{p}) = \sqrt{\frac{\hat{p}(1-\hat{p})}{N}}.$$

Para $\hat{p} \approx 0{,}09$ (valor típico nos experimentos) e $N = 500$:

$$\text{EP} = \sqrt{\frac{0{,}09 \times 0{,}91}{500}} \approx 0{,}013.$$

Portanto, com $N = 500$ amostras, o p-valor estimado tem precisão de $\pm 0{,}013$ — suficiente para distinguir valores próximos de 0,05. **Aumentar N além de 500 melhora a precisão, mas não altera o p-valor verdadeiro.**

O z-score: medida contínua de separação

Independentemente do limiar de 0,05, a separação entre a SLO e o acaso pode ser medida continuamente pelo **z-score**:

$$z = \frac{\mu_{\text{rnd}} - \bar{r}(\sigma_{\text{SLO}})}{\sigma_{\text{rnd}}}.$$

O z-score mede quantos desvios padrão a SLO está abaixo da média aleatória. A correspondência com o p-valor (aproximação normal) é:

$$p \approx \Phi(-z) = 1 - \Phi(z),$$

onde Φ é a função de distribuição acumulada normal padrão.

z	$p \approx \Phi(-z)$	Interpretação
1,282	0,10	Tendência
1,645	0,05	Significativo ($*$)
2,326	0,01	Altamente significativo ($**$)
3,090	0,001	Muito altamente significativo ($***$)

Tabela 1: Resultados do teste de permutação para grafos $G(9, p)$. Γ: número de Grundy; $|\mathrm{OPT}|$: número de soluções ótimas; $\bar{r}_{\mathrm{SLO}}$: rank médio normalizado da SLO; μ_{rnd}, σ_{rnd}: média e desvio padrão da distribuição aleatória ($N = 500$); $\hat{p}$: p-valor empírico; z: z-score; $\Delta = \mu_{\mathrm{rnd}} - \bar{r}_{\mathrm{SLO}}$.

p	Γ	$\lvert\mathrm{OPT}\rvert$	$\bar{r}_{\mathrm{SLO}}$	μ_{rnd}	σ_{rnd}	min	max	$\hat{p}$	z
0,10	3	181 440	0,561	0,944	0,270	0,167	1,689	0,082	1,42
0,25	4	4 158	0,000	1,165	0,700	0,000	3,000	0,094	1,66
0,50	6	325	0,000	0,670	0,408	0,000	1,833	0,092	1,64
0,75	7	4 320	0,000	0,513	0,353	0,000	1,571	0,126	1,45
0,90	7	80 640	0,000	0,528	0,297	0,000	1,286	0,060	1,78

Resultados experimentais

Os experimentos foram conduzidos com grafos aleatórios de Erdős-Rényi $G(n, p)$ para $n = 9$ e cinco densidades, com $N = 500$ ordens aleatórias por grafo. A Tabela 1 apresenta os resultados.

Leitura dos resultados

Nenhum resultado individualmente significativo ao nível 5%. Todos os p-valores ficam entre 0,06 e 0,13, acima do limiar convencional de 0,05. Isso não implica que a hipótese nula é verdadeira, mas que a evidência individual por grafo é insuficiente para rejeitá-la com $n = 9$.

O sinal é consistente e não aleatório. Três observações apontam para um efeito real:

- $\Delta > 0$ em todos os 5 casos: a SLO sempre produz rank médio menor que a média do acaso.
- Os z-scores estão entre 1,42 e 1,78 — consistentemente próximos do limiar de significância.
- $\bar{r}_{\mathrm{SLO}} = 0$ em 4 de 5 casos: a SLO atinge o melhor caso possível (representantes nas posições mais prioritárias) com frequência muito maior do que o acaso.

O problema do piso zero. Quando $\bar{r}_{\mathrm{SLO}} = 0$, qualquer outra ordem que também atinja 0 contribui para o p-valor — e o histograma mostra que ordens aleatórias atingem 0 com probabilidade entre 6% e 13%. A SLO não pode melhorar além de 0, então a separação estatística fica limitada pelo piso da distribuição, não pela qualidade da SLO.

Combinação de testes: Método de Fisher

Quando múltiplos testes independentes produzem resultados individualmente não significativos mas consistentemente favoráveis, o **método de Fisher** combina os p-valores em um único teste global.

Definição: Estatística de Fisher

Dados k testes independentes com p-valores $\hat{p}_1, \ldots, \hat{p}_k$, a estatística de Fisher é

$$\chi_F^2 = -2 \sum_{i=1}^{k} \ln(\hat{p}_i),$$

que segue uma distribuição χ^2 com $2k$ graus de liberdade sob H_0 (independência e uniformidade dos p-valores).

Aplicando aos cinco p-valores observados:

$$\begin{aligned}\chi^2_F &= -2\big(\ln 0{,}082 + \ln 0{,}094 + \ln 0{,}092 + \ln 0{,}126 + \ln 0{,}060\big)\\ &= -2\big(-2{,}501 - 2{,}364 - 2{,}386 - 2{,}071 - 2{,}813\big)\\ &= -2 \times (-12{,}135) \;=\; 24{,}27.\end{aligned}$$

Com $2 \times 5 = 10$ graus de liberdade, a tabela χ^2 fornece:

$$P(\chi^2_{10} > 24{,}27) \approx 0{,}007.$$

Resultado

O método de Fisher combina os cinco testes individuais e produz $\chi^2_F = 24{,}27$ com $p \approx 0{,}007$ ($< 0{,}01$). Isso indica que, **globalmente**, a evidência contra a hipótese nula é altamente significativa: a SLO posiciona os representantes de forma sistematicamente melhor que o acaso, mesmo que nenhum grafo individual produza evidência suficiente.

Implicações para a formulação de representantes

A validação estatística do alinhamento semântico tem consequências diretas para a qualidade do modelo de programação inteira.

Qualidade da relaxação LP

Se a SLO posiciona os representantes naturais com σ pequeno, a variável $x_{u,u}$ correspondente é criada para os vértices que *deveriam* ser representantes. A relaxação LP tende a atribuir $x_{u,u}$ fracionário próximo de 1 para esses vértices, pois as restrições M4 penalizam outros arranjos. Isso produz um limitante dual de melhor qualidade logo no nó raiz da árvore de branch-and-bound.

Formalmente, quanto mais $\bar{r}(\sigma_{\text{SLO}})$ se aproxima de 0, mais a estrutura de $\mathcal{X}$ reflete a estrutura ótima do problema, e menor tende a ser o gap de integralidade na raiz:

$$\text{gap}_{\text{raiz}} \;=\; \frac{\text{OBJ}_{\text{LP}} - \text{OBJ}_{\text{IP}}}{\text{OBJ}_{\text{IP}}}.$$

Redução do espaço de busca

O número de nós explorados pelo solver depende do gap na raiz e da simetria residual do modelo. Uma ordem que coloca os representantes naturais mais cedo reduz a ambiguidade: há menos pares de vértices que poderiam trocar de papel (representante/membro) sem alterar a solução. Isso se traduz diretamente em menos branching necessário.

Coerência semântica

A SLO não é apenas uma heurística ad hoc: ela tem justificativa estrutural. Os vértices de maior grau residual (aqueles com σ pequeno na SLO) são os mais prováveis representantes porque:

- Um representante u da classe i precisa ter pelo menos um vizinho em cada classe $j < i$. Isso exige alto grau em G.
- Na SLO, vértices de alto grau residual têm σ pequeno e portanto muitos não-vizinhos à frente na ordem — exatamente os candidatos a membros de sua classe.

O teste de permutação confirma empiricamente essa coerência: $\bar{r}(\sigma_{\text{SLO}}) = 0$ em 4 de 5 grafos testados, e o método de Fisher confirma que esse resultado é globalmente significativo com $p < 0{,}01$.

Limitações e extensões

Atenção

As conclusões acima são baseadas em grafos pequenos ($n = 9$) devido à necessidade de enumerar todas as soluções ótimas por força bruta. Para $n \geq 12$, seria necessário um algoritmo exato de branch-and-bound para computar $\mathrm{OPT}(G)$, o que tornaria o estudo computacionalmente viável para instâncias maiores — onde o efeito da SLO provavelmente seria ainda mais pronunciado, pois o z-score cresce com n à medida que o espaço de permutações aumenta fatorialmente.

Uma extensão natural seria usar a **correlação de Spearman** entre $\sigma(v)$ e a frequência com que v atua como representante em $\mathrm{OPT}(G)$, definida como

$$\rho_s = 1 - \frac{6 \sum_v d_v^2}{n(n^2 - 1)},$$

onde $d_v = \sigma(v) -$ rank de frequência de v como representante. Essa métrica é contínua e não sofre do problema do piso zero, potencialmente tornando o teste mais poderoso para n pequeno.